



UNIVERSITATEA TEHNICĂ

DIN CLUJ-NAPOCA

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE

SINTEZA
 proiectului de diplomă cu titlul:

**APLICAȚIE MOBILĂ PENTRU ANALIZA ÎN TIMP REAL A POSTURII
 UTILIZATORILOR FOLOSIND VIZIUNE ARTIFICIALĂ**

Autor: **Antonia-Maria TARTĂ**

Coordonator: **ŞI. Dr. Ing. Vlad Cristian MICLEA**

1. Cerințele temei:

Lucrarea de licență a avut ca obiectiv identificarea unei soluții care să permită analiza în timp real a posturii utilizatorilor care desfășoară activități la birou, deoarece o postură incorectă poate avea efecte negative asupra sistemului osos și muscular. În acest scop, a fost realizată o aplicație mobilă care utilizează viziunea artificială pentru monitorizarea posturală. Aceasta a fost concepută să funcționeze fără conexiune la internet și fără echipamente suplimentare care să implice costuri adiționale pentru utilizatori.

2. Soluții alese:

În Figura 1 este prezentată arhitectura conceptuală a aplicației. Aceasta este organizată pe module care au o funcție specifică și descriu întregul proces de analiză a posturii: achiziția, prelucrarea și clasificarea imaginii, interpretarea rezultatului.

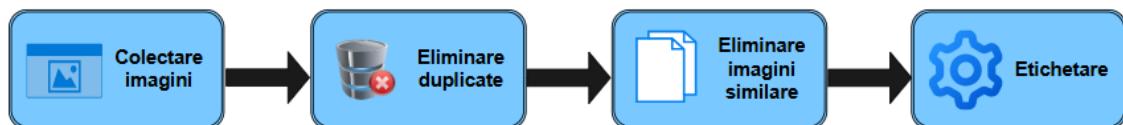


Figură 1. Arhitectura conceptuală

Modulul de clasificare este componenta principală a sistemului deoarece aici se află integrat modelul antrenat pentru identificarea posturilor utilizatorilor. Au fost testate mai multe arhitecturi (ResNet50, EfficientNet3, MobileNetV2), iar modelul DenseNet121 a oferit cele mai bune rezultate. Din cauza confuziilor dintre postura neutră detectată în imaginile laterale și frontale, clasificarea se realizează diferit în funcție de perspectivă. Aplicația utilizează modelul antrenat corespunzător pentru acel unghi. Arhitectura modelului a fost extinsă pentru a se adapta problemei abordate, iar antrenarea a fost realizată în două etape (transfer de cunoștințe și fine-tuning).

Modelul a fost antrenat pe un set de date propriu care ilustrează persoane desfășurând activități la birou. Acest set de date a fost construit parcurgându-se etapele din Figura 2. Curățarea acestuia a fost necesară pentru că în starea inițială, modelul supraînvăță și avea o capacitate slabă de generalizare. Etichetarea se face în mod automat, respectând etapele

din Figura 3. După ce punctele cheie sunt identificate, se aplică regulile conturate de specialiștii în ergonomie. Etichetele atribuite sunt: postură neutră, cocoșată, lăsată în scaun, simetrică, asimetrică.



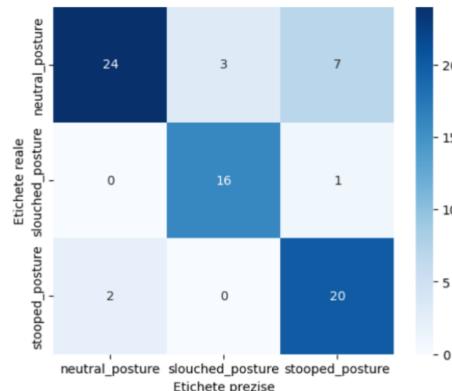
Figură 2. Construirea setului de date



Figură 3. Etichetarea setului de date

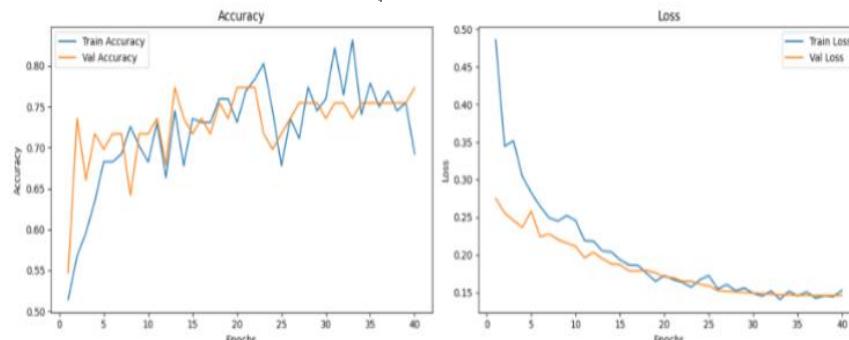
3. Rezultate obținute:

Matricea de confuzie (Figura 4) conturează abilitatea modelului de a distinge între clase. Clasa slouched_posture (lăsată în scaun) a fost clasificată corect în 16 din 17 cazuri, iar stooped_posture (cocoșată) în 20 din 22. Cele mai multe confuzii s-au produs între neutral_posture (postură neutră) și stooped_posture, acestea fiind apropiate vizual.



Figură 4. Matricea de confuzie (perspectiva laterală)

Graficele din Figura 5 prezintă o creștere a acurateței pe seturile de antrenare și validare, în timp ce pierderea scade constant, sugerând o capacitate bună a modelului de a învăța trăsăturile. Totuși, se observă fluctuații în evoluția acurateței, explicabile prin faptul că setul de date este relativ redus și dezechilibrat.



Figură 5. Evoluția acurateței și pierderii (perspectivă frontală)

Modelul DenseNet121 antrenat pentru clasificarea posturii (laterală) a atins o acuratețe de 82,1%, cu o pierdere (loss) de 0.18. Precizia macro a fost de 83%, recall-ul de 85%, iar scorul F1 macro a fost de 83%. Pentru perspectiva frontală, modelul a fost antrenat în aceleși condiții și a obținut o acuratețe de aproximativ 80% și o valoarea a funcției de pierdere de 0,15.

4. Testări și verificări:

Modelul DenseNet121 a fost evaluat pe un set de test diferit, nevăzut la antrenament, reprezentând 10% din totalul datelor. Pentru validare au fost utilizate metrice precum acuratețea, precizia, recall-ul și scorul F1. Rezultatele obținute au fost prezentate în Secțiunea 3, alături de analiza curbelor de învățare și a matricei de confuzie.

Aplicația a fost testată atât pe emulator Android, cât și pe un dispozitiv real (Samsung Galaxy S23 FE). S-au verificat funcționalitățile principale, precum achiziția imaginii, analiza posturii și afișarea feedbackului. De asemenea, 11 utilizatori (4 femei și 7 bărbați) au testat aplicația. Toți au reușit să o folosească fără să întâmpine dificultăți și fără să dorească explicații referitoare la modul de utilizare. Un singur utilizator a considerat că el adoptă mereu o poziție corectă și că postura neutră luată în considerare de aplicație este prea restrictivă.

5. Contribuții personale:

- Colectarea imaginilor pentru setul de date
- Etichetarea imaginilor
- Antrenarea și compararea mai multor modele (ResNet50, EfficientNet3, MobileNetV2, DenseNet121)
- Dezvoltarea aplicației mobile Android
- Integrarea modelului în aplicație
- Testarea aplicației

6. Surse de documentare:

- [1] I. Goodfellow, Y. Bengio, A. Courville, and Y. Bengio, Deep learning. MIT press Cambridge, 2016, vol. 1, no. 2.
- [2] R. Moreira, R. Fialho, A. S. Teles, V. Bordalo, S. S. Vasconcelos, G. P. de Moraes Gouveia, V. H. Bastos, and S. Teixeira, “A computer vision-based mobile tool for assessing human posture: A validation study”, Computer methods and programs in biomedicine, vol. 214, p. 106565, 2022.
- [3] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in Proceedings of the IEEE conference on computer vision and pattern recognition, 2017, pp. 4700–4708.